

6.2

```
def calcular_c(err,x,y):  
  
    #calculo w  
    w = 1/np.square(err)  
  
    #terminos suma  
    a = np.sum(w*np.square(x))  
    b = np.sum(w*y)  
    c = np.sum(w*x)  
    d = np.sum(w*x*y)  
  
    #terminos delta  
    e = np.sum(w)  
    f = np.sum(w*np.square(x))  
    g = np.square(np.sum(w*x))  
    delta = f*e - g  
  
    #calculo c  
    c = (a*b - c*d)/delta  
  
    return c
```

```
def calcular_m(err,x,y):  
  
    #calculo w  
    w = 1/np.square(err)  
  
    #terminos suma  
    a = np.sum(w)  
    b = np.sum(w*x*y)  
    c = np.sum(w*x)  
    d = np.sum(w*y)  
  
    #terminos delta  
    e = np.sum(w)  
    f = np.sum(w*np.square(x))  
    g = np.square(np.sum(w*x))  
    delta = f*e - g  
  
    #calculo m  
    m = (a*b - c*d)/delta  
  
    return m
```

```
def calcular_ac(err,x):  
  
    #calculo w  
    w = 1/np.square(err)  
  
    #terminos suma  
    a = np.sum(w*np.square(x))  
  
    #terminos delta  
    e = np.sum(w)  
    f = np.sum(w*np.square(x))  
    g = np.square(np.sum(w*x))  
    delta = f*e - g  
  
    #calculo ac  
    ac = np.sqrt(a/delta)  
  
    return ac
```

```
def calcular_am(err,x):  
  
    #calculo w  
    w = 1/np.square(err)  
  
    #terminos suma  
    a = np.sum(w)  
  
    #terminos delta  
    e = np.sum(w)  
    f = np.sum(w*np.square(x))  
    g = np.square(np.sum(w*x))  
    delta = f*e - g  
  
    #calculo am  
    am = np.sqrt(a/delta)  
  
    return am
```

c
✓ 0.0s

-0.9474964662767381

m
✓ 0.0s

2.0284648216102745

ac
✓ 0.0s

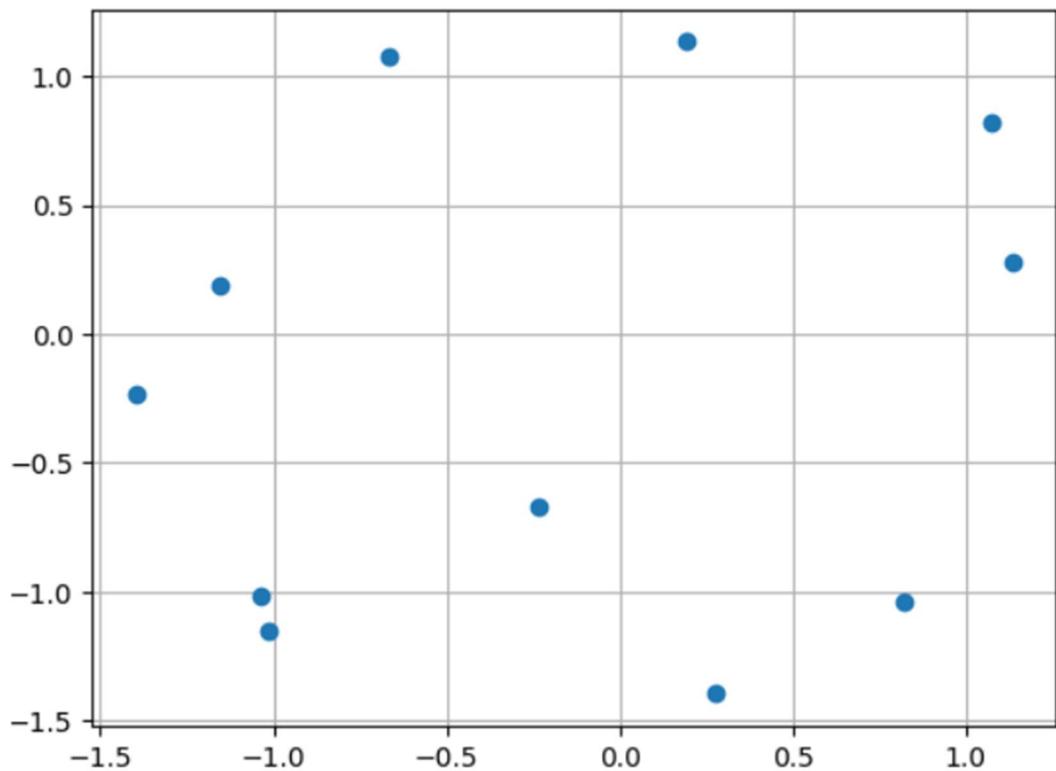
3.386858673521736

am
✓ 0.0s

0.05197830827721802

```
model = c + m*frecuencia
residuals = voltaje-model
normalized_residuals = residuals/error
lagged = np.roll(normalized_residuals, -1)
plt.plot(normalized_residuals, lagged, 'o')
plt.grid()
plt.show()
```

Lagged plot

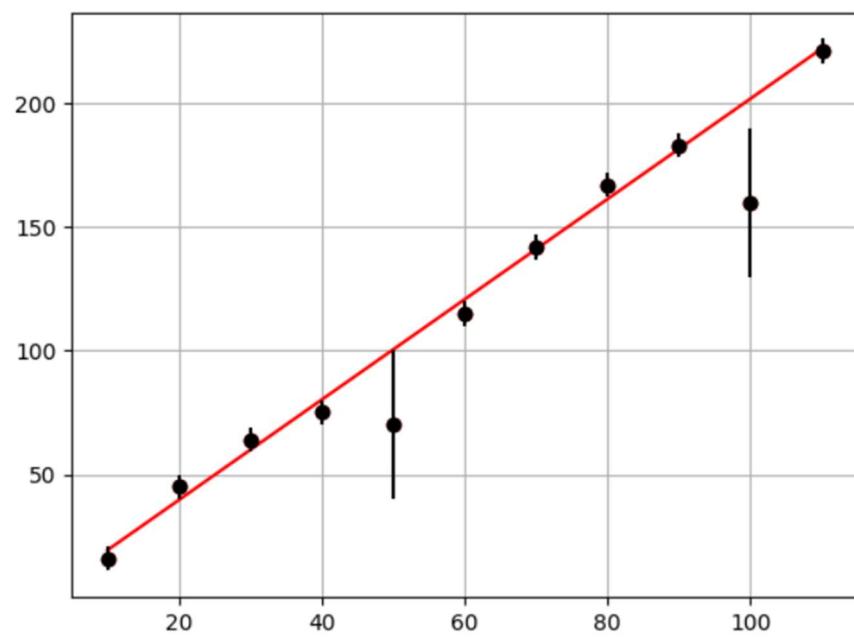


```
46] def Durbin_Watson(residuals):
    return np.sum(np.square(normalized_residuals-lagged))/np.sum(normalized_residuals**2)
    ✓ 0.0s

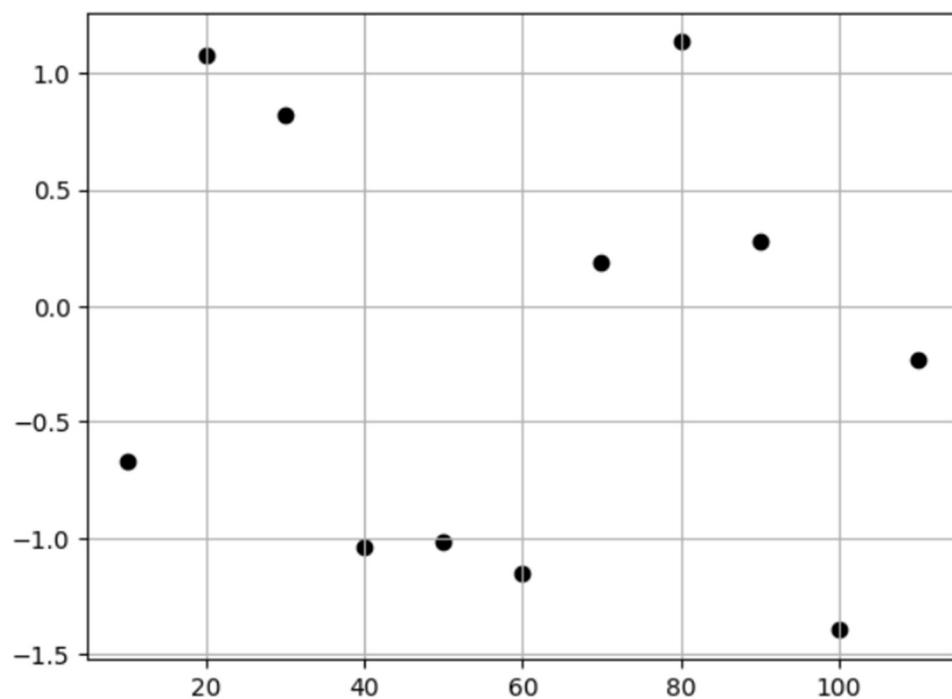
47] D = Durbin_Watson(residuals)
D
    ✓ 0.0s
· 1.572140044519231
```

6.3

Datos con best-fit line



Normalized residuals



6.4

```
def chi2(M, C):
    res = ((voltaje - (M * frecuencia + C)) / error) ** 2
    return np.sum(res)

✓ 0.0s

M_values = np.linspace(1, 3, 1000)
C_values = np.linspace(-1, 1, 1000)
best_chi = np.inf
# Calculate chi-squared for each combination of parameters
chi2_grid = np.zeros((len(M_values), len(C_values)))
for i, M in enumerate(M_values):
    for j, C in enumerate(C_values):
        chi2_grid[i, j] = chi2(M, C)
        if chi2_grid[i, j] < best_chi:
            best_chi = chi2_grid[i, j]
            best_M = M
            best_C = C

✓ 8.0s
```

```

best_M
252] ✓ 0.0s
...
2.029029029029029

best_c
253] ✓ 0.0s
...
-0.97997997997998

best_chi
254] ✓ 0.0s
...
9.116021484725753

```

```

def solve_Espacio_fase_c(m=m_min,c=c_min,x=x,y=y,contorno=1,alpha=dy,gmm=0.0001,infer=-1,tolerancia=1e-7):
    mjAnterior = m
    d = 1
    cj = c

    while d>tolerancia:
        #Loop que minimiza c
        cjAnterior = cj

        cj = newt(f_c,cj+0.01*infer,args=(mjAnterior,x,y,alpha,contorno)) #Newton rapshon para minimizar c

        termino = 2*gmm*np.sum(x*(y-(mjAnterior)*x-cj)/(alpha)**2)

        mjAnterior += termino

        diff=np.abs(cj-cjAnterior)

        d = diff

    return cj

```

```

def solve_Espacio_fase_m(m=m_min,c=c_min,x=x,y=y,contorno=1,alpha=dy,gmm=0.05,infer=-1,tolerancia=1e-7):
    cjAnterior = c
    d = 1
    mj = m

    while d>tolerancia:
        #loop que minimiza m

        mjAnterior = mj

        mj = nwt(f_m,mj+0.02*infer,args=(cjAnterior,x,y,alpha,contorno)) #Newton rapshon para minimizar m

        termino = 2*gmm*np.sum((y-(mj)*x-cjAnterior)/(alpha)**2)

        cjAnterior += termino

        diff=np.abs(mj-mjAnterior)

        d = diff

    return mj

```

Errores calculados de m y c:

Contorno 1:

Inferior:

```

m:
-0.017325659748360422

```

```

c:
-1.1289533645592529

```

Superior:

```

m:
0.017325677963016872

```

```

c:
1.1289523737901974

```

Contorno 4:

Inferior:

m:

-0.03465177823317589

c:

-2.2579062566317956

Superior:

m:

0.03465179644876434

c:

2.257905265862669

Contorno 9:

Inferior:

m:

-0.05197786414732053

c:

-3.3868591537285657

Superior:

m:

0.05197788236315951

c:

3.386858162959412

Esto se ajusta bastante bien a lo esperado.

6.5

c	
✓	0.0s
-0.10700883885508011	
m	
✓	0.0s
1.2397219665412587	
ac	
✓	0.0s
0.03266514103078884	
am	
✓	0.0s
0.03925005362824148	

$$M = 1.24 \pm 0.04$$

$$C = -0.11 \pm 0.03$$

Calculando la velocidad de la luz tenemos:

$$V_c = 304025095.50870967 \pm 9807260.370254517$$

Ósea

$$V_c = 3.04 \times 10^8 \pm 0.10 \times 10^8$$

El intercepto no es consistente, pero la velocidad de la luz da razonable.

6.6

i) Errores originales

c	✓ 0.0s
	1.7267713877515376
m	✓ 0.0s
	49.89790121339644
ac	✓ 0.0s
	0.9872895098081177
am	✓ 0.0s
	0.31658015706387804

ii) Errores ctes de 4

c	✓ 0.0s
	-1.0
m	✓ 0.0s
	50.472727272727276
ac	✓ 0.0s
	2.7325202042558927
am	✓ 0.0s
	0.4403855060505442

iii) errores 1 y final de 1, el resto de 8

0]	c	✓ 0.0s
-0.45340345705480367		
1]	m	✓ 0.0s
51.19874715261959		
2]	ac	✓ 0.0s
1.0979945499870805		
3]	am	✓ 0.0s
0.155877022570768		

A pesar de que no cambiamos los datos usados, tan solo cambiar los errores asociados a las mediciones impactó fuertemente el resultado. Esto, claramente se da porque en un cálculo con pesos de los mejores valores para la pendiente y corte, entre más preciso sea el dato, más contribuirá al resultado final. Por esto cambiar dichas precisiones afecta nuestros valores óptimos calculados.

8.2)

$$\text{a) } X_{\nu}^2 = \frac{x_{\min}^2}{\nu} = \frac{15.9}{10} = 1.59$$

$$\text{b) } X(x^2; \nu) = \frac{(x^2)^{\frac{\nu}{2}-1}}{2^{\nu/2} \Gamma(\nu/2)} \exp\{-x^2/2\}; P(x_{\min}^2; \nu) = \int_{x_{\min}^2}^{\infty} X(x^2; \nu) dx^2$$

$$X(x^2; 10) = \frac{(x^2)^4 \exp\{-x^2/2\}}{2^5 4!}$$

$$\therefore P(x_{\min}^2; 10) = \frac{1}{768} \int_{15.9}^{\infty} (x^2)^4 \exp\{-x^2/2\} dx^2$$

$$\begin{array}{c} \text{D} \\ (x^2)^4 \\ + \\ 4(x^2)^3 \\ - \frac{1}{2} \\ 12(x^2)^2 \\ + \frac{1}{4} \\ 24(x^2) \\ - \frac{1}{8} \\ 24 \\ + \frac{1}{16} \\ 0 \\ - \frac{1}{32} \end{array} \quad \begin{array}{c} \text{I}^2 \\ \exp\{-x^2/2\} \\ \downarrow \end{array}$$

$$\therefore P(x_{\min}^2; 10) = -\frac{1}{168} \exp\{-x^2/2\} \left[\frac{(x^2)^4}{2} + (x^2)^3 + \frac{3}{2} [(x^2)^2 + (x^2)] + \frac{3}{4} \right] \Big|_{15.9}^{\infty}$$

$$P(x_{\min}^2; 10) = 0.1 \approx 10\%$$

$$\text{c) Para } \nu = 100; x_{\min}^2 = 15.9$$

$$X_{\nu}^2 = \frac{x_{\min}^2}{\nu} = \frac{15.9}{100} = 1.59$$

$$\text{d) } P(x_{\min}^2; 100) = \frac{1}{2^{50} 49!} \int_{15.9}^{\infty} (x^2)^{49} \exp\{-x^2/2\} dx^2 =$$

$$\therefore P(x_{\min}^2; 100) \approx 0.00016$$

Vemos que al aumentar los grados de libertad, disminuye la probabilidad de obtener un valor de x_{\min}^2 , luego para 10 grados es un mejor fit. Además, $x_{\min}^2 > \chi^2 + 3\sqrt{2\sigma^2}$, 100 \Rightarrow pero para 10 \Rightarrow no.

8.3) $N=2500$

$$\text{Eq. 3.9} \Rightarrow P(x_1 \leq x \leq x_2) = \frac{1}{\sqrt{2\pi}} \int_{x_1}^{x_2} \exp\left\{-\frac{(x-\bar{x})^2}{2\sigma^2}\right\} dx$$

$$E_i = N \cdot P$$

$$= E_i F(x_2; \bar{x}; \sigma) - E_i F(x_1; \bar{x}; \sigma), \text{ pero sea } \sigma=1; \bar{x}=0$$

Usando Wolfram

x_1	x_2	O_i	P	E_i	$\frac{(O_i - E_i)^2}{E_i}$
-oo	-2.5	9	0.0062	15.5	2.73
-2.5	-2	48	0.0165	41.25	1.02
-2	-1.5	142	0.044	110	9.418
-1.5	-1	154	0.0919	230	25.348
-1	-0.5	438	0.1498	374.5	10.76
-0.5	0	521	0.1914	478.5	3.775
0	0.5	405	0.1914	478.5	11.289
0.5	1	318	0.1498	374.5	8.524
1	1.5	299	0.0919	230	20.7
1.5	2	100	0.044	110	0.909
2	2.5	57	0.0165	41.25	6.07
2.5	oo	9	0.0062	15.5	2.73

i) Podemos ver que todos los $E_i > 5$, luego 10 hace falta combinar

$$\text{ii)} \chi^2 = \sum \frac{(O_i - E_i)^2}{E_i} = 103.213$$

$$\text{iv)} \nu = N - N$$

$$\nu = 12 - 2$$

$$\underline{\nu = 10}$$

v) No es consistente con la hipótesis de una distribución Gaussiana,

8.5) $N = 101$

x_1	x_2	O_i	E_i	$\frac{(O_i - E_i)^2}{E_i}$
1	10	6	11.2	2.43
11	20	11	11.2	0.0044
21	30	8	11.2	0.925
31	40	8	11.2	0.925
41	50	14	11.2	0.687
51	60	12	11.2	0.0539
61	70	11	11.2	0.0044
71	80	12	11.2	0.0539
81	90	19	11.2	5.391
			χ^2	10.475

i) Como es uniforme,
esperamos la misma

cantidad de goles en
cada intervalo

$$ii) E_i = \frac{101}{9} \checkmark$$

iii) Podemos ver que
 $E_i > 5$ en todos

$$iv) \chi^2 = 10.475$$

v) Como solo hay una
restricción:

$$v) D = 9 - 1 \Rightarrow D = 8$$

$$v) \chi^2_D = \frac{10.475}{8} = 1.309$$

$\chi^2_D \approx 1$, luego
es un buen fit.

8.7)

FV	1	2	3	4	5	6
O_i	17	21	14	13	16	19
$\frac{(O_i - E_i)^2}{E_i}$	0.005	1.126	0.426	0.806	0.026	0.326

Dibujarla ser uniforme
entonces deberíase ser

$$E_i = \frac{100}{6} = 16.6$$

$$\chi^2 = 2.72 ; v = 6 - 1 = 5$$

Viendo en una tabla, para 5 grados de libertad, veímos
que a partir del 10% de probabilidad $\chi^2 = 9.24$,
y entre más disminuye la probabilidad χ^2 aumenta.

Luego $\chi^2 < 9.24$.



Osea, que un 90% de las veces que caiga el dado dará un valor correcto.

Luego el dado sí es justo.



c

✓ 0.0s

-0.10700883885508011

m

✓ 0.0s

1.2397219665412587

ac

✓ 0.0s

0.03266514103078884

am

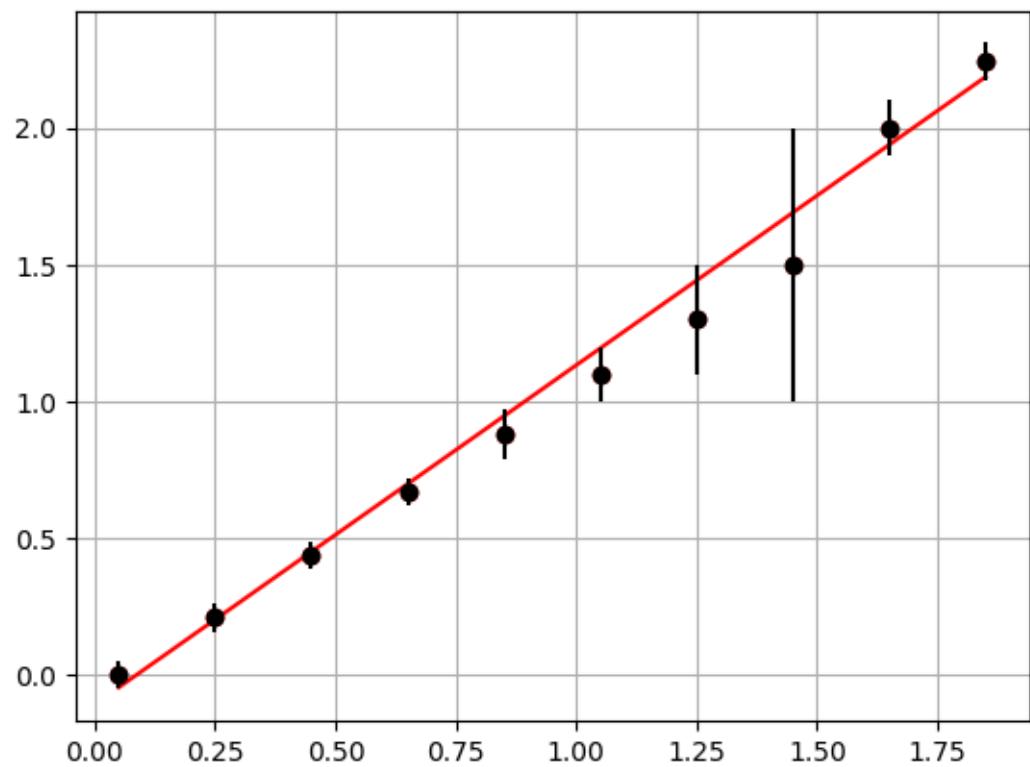
✓ 0.0s

0.03925005362824148

best_chi

✓ 0.0s

4.273774137517402



c

✓ 0.0s

-0.02857142857142859

m

✓ 0.0s

431.71428571428567

ac

✓ 0.0s

0.0845154254728517

am

✓ 0.0s

0.7559289460184546

best_chi

✓ 0.0s

1547225.75

